МОСКОВСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ им. Н.Э. Баумана

Факультет «Информатика и система управления» Кафедра ИУ-5 «Системы обработки информации и управления»

ОТЧЕТ

Лабораторная работа №3 по курсу «Методы машинного обучения»

Исполнитель - студент группы ИУ5-21М:

Кауров Максим _____

```
from google.colab import files
import numpy as np
import pandas as pd
import seaborn as sns
import sklearn.impute
import sklearn.preprocessing
import matplotlib.pyplot as plt
%matplotlib inline
sns.set(style="ticks")
from IPython.display import set_matplotlib_formats
set_matplotlib_formats("retina")
uploaded = files.upload()
for fn in uploaded.keys():
  print('User uploaded file "{name}" with length {length} bytes'.format(
      name=fn, length=len(uploaded[fn])))
     Выбрать файлы Файл не выбран
                                        Upload widget is only available when the cell has been executed
     the current browser session. Please rerun this cell to enable.
     Saving PatientInfo.csv to PatientInfo (2).csv
     User unloaded file "PatientInfo.csv" with length 220884 hytes
data = pd.read_csv('PatientInfo.csv')
```

Информация о датасете

В качестве датасета для лабораторной работы был выбран датасет с подтвержденной инф COVID-19 в Южной Корее

data.head()

dise	city	province	country	age	birth_year	sex	global_num	patient_id	•
1	Gangseo- gu	Seoul	Korea	50s	1964.0	× ale			Saving
1	Jungnang- gu	Seoul	Korea	30s	1987.0	male	5.0	1000000002	1
1	Jongno-gu	Seoul	Korea	50s	1964.0	male	6.0	1000000003	2
1	Mapo-gu	Seoul	Korea	20s	1991.0	male	7.0	1000000004	3
1	Seongbuk- gu	Seoul	Korea	20s	1992.0	female	9.0	1000000005	4

data.isnull().sum()

```
patient id
global_num
                        904
                        145
sex
birth_year
                        454
                        261
age
country
                          0
                          0
province
                         65
city
                       2199
disease
infection_case
                       1055
infection order
                       2176
infected by
                       1749
                       1807
contact_number
symptom_onset_date
                       2025
confirmed_date
                        141
released_date
                       1995
deceased date
                       2186
                         88
state
dtype: int64
```

Обработка пропусков в данных

Осуществлено методом установки 0, среднего значения, медианного значения и методом у значения.

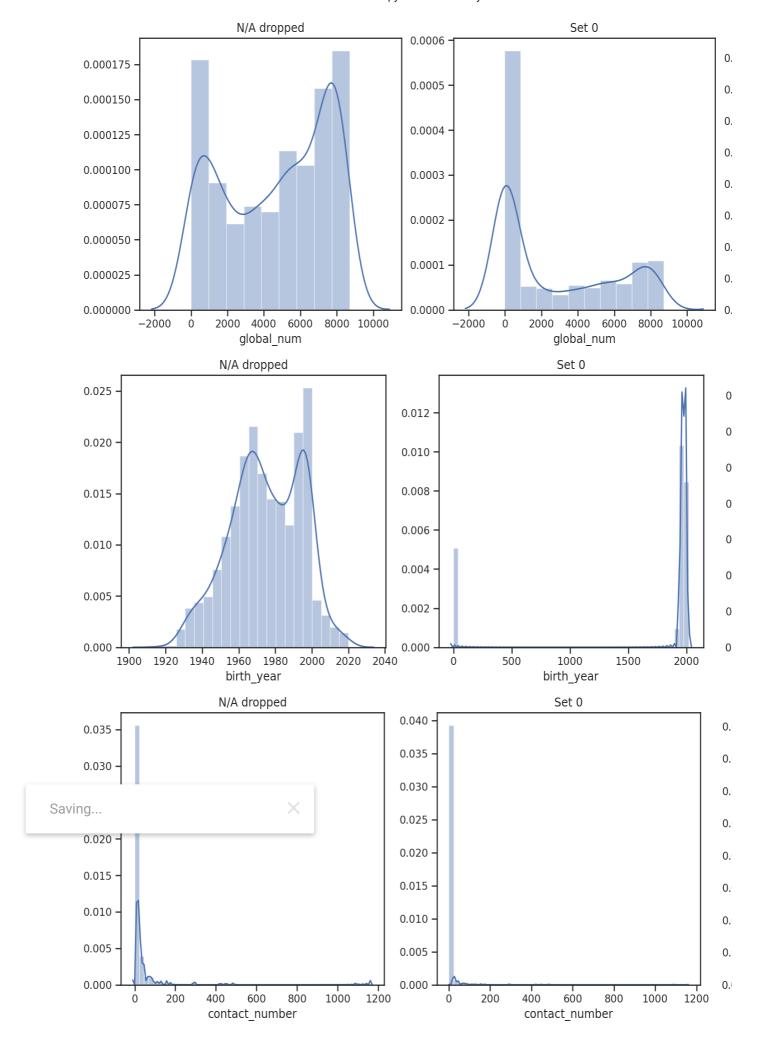
```
mean_imp = sklearn.impute.SimpleImputer(strategy="mean")
   med imp = sklearn.impute.SimpleImputer(strategy="median")
   fig, ax =plt.subplots(1,5, figsize=(30,5))
   ax[0].set_title('N/A dropped')
   ax[1].set_title('Set 0')
   ax[2].set title('Impute strategy mean')
   ax[3].set_title('Impute strategy median')
   ax[4].set title('Forward filling')
   sns.distplot(data["global_num"].dropna(), ax=ax[0])
   sns.distplot(data["global_num"].fillna(0), ax=ax[1])
   sns.distplot(mean_imp.fit_transform(data[["global_num"]]), ax=ax[2])
                                         'ata[["global_num"]]), ax=ax[3])
                                         na(method='ffill'), ax=ax[4])
     Saving...
   fig, ax =plt.subplots(1,5, figsize=(30,5))
   ax[0].set title('N/A dropped')
   ax[1].set title('Set 0')
   ax[2].set title('Impute strategy mean')
   ax[3].set_title('Impute strategy median')
   ax[4].set title('Forward filling')
   sns.distplot(data["birth_year"].dropna(), ax=ax[0])
   sns.distplot(data["birth_year"].fillna(0), ax=ax[1])
   sns.distplot(mean_imp.fit_transform(data[["birth_year"]]), ax=ax[2])
   sns.distplot(med_imp.fit_transform(data[["birth_year"]]), ax=ax[3])
   sns.distnlot(data["hirth vear"].fillna(method='ffill'). ax=ax[4])
https://colab.research.google.com/drive/13momAhZfFv-IU78jo66XgnRE3VSPYsM4#scrollTo=-IJCMpmF rSn&printMode=true
```

```
fig.show()

fig, ax =plt.subplots(1,5, figsize=(30,5))
ax[0].set_title('N/A dropped')
ax[1].set_title('Set 0')
ax[2].set_title('Impute strategy mean')
ax[3].set_title('Impute strategy median')
ax[4].set_title('Forward filling')
sns.distplot(data["contact_number"].dropna(), ax=ax[0])
sns.distplot(data["contact_number"].fillna(0), ax=ax[1])
sns.distplot(mean_imp.fit_transform(data[["contact_number"]]), ax=ax[2])
sns.distplot(data["contact_number"].fillna(method='ffill'), ax=ax[4])
fig.show()
```



Saving... ×



▼ Кодирование категориальных признаков

Кодирование категорий целочисленными значениями

```
from \ sklearn.preprocessing \ import \ Label Encoder, \ One Hot Encoder
```

```
le = LabelEncoder()
data_age = le.fit_transform(data['age'].dropna())
data['age'].dropna().unique()

print(np.unique(data_age))
le.inverse_transform(np.unique(data_age))

[ 0 1 2 3 4 5 6 7 8 9 10]
    array(['0s', '100s', '10s', '20s', '30s', '40s', '50s', '60s', '70s', '80s', '90s'], dtype=object)
```

Кодирование категорий наборами бинарных значений

```
ohe = OneHotEncoder()
data_province = ohe.fit_transform(data[['province']].dropna())
data_province.todense()[0:4]
```

Быстрый вариант one-hot кодирования

```
data_city = pd.get_dummies(data['city'].dropna())
Saving...
```

	Andong- si	Ansan- si	Anseong- si	Anyang- si	Asan- si	Bonghwa- gun	Bucheon- si	Buk- gu	Bupyeong- gu	Bus
0	0	0	0	0	0	0	0	0	0	
1	0	0	0	0	0	0	0	0	0	
2	0	0	0	0	0	0	0	0	0	
3	0	0	0	0	0	0	0	0	0	
4	0	0	0	0	0	0	0	0	0	

5 rows × 134 columns

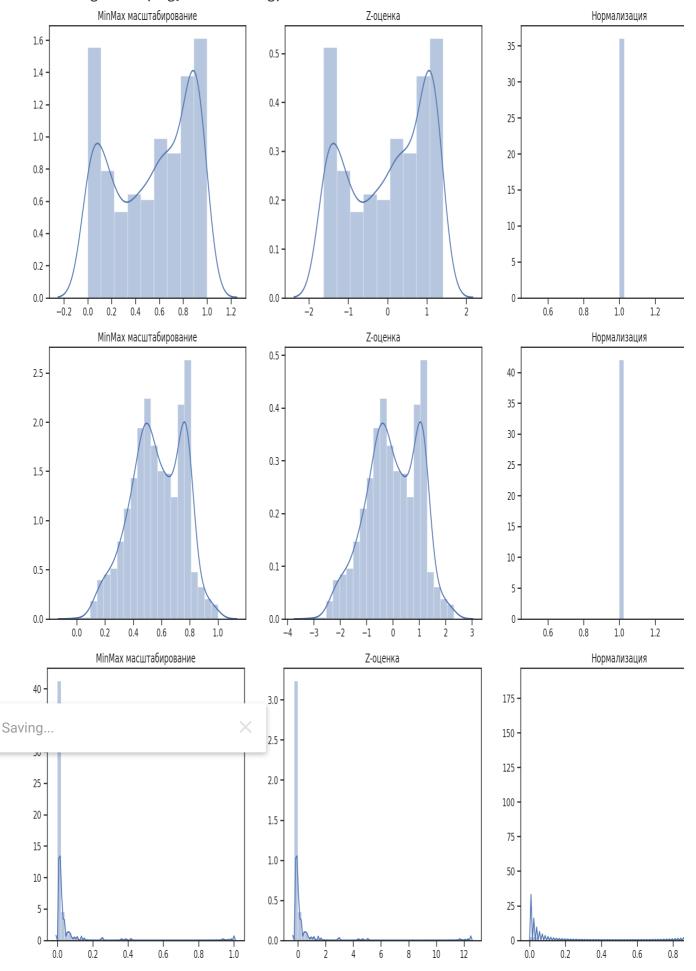
▼ Масштабирование данных

```
sc1 = sklearn.preprocessing.MinMaxScaler()
sc2 = sklearn.preprocessing.StandardScaler()
sc3 = sklearn.preprocessing.Normalizer()
fig, ax =plt.subplots(1,3, figsize=(20,5))
ax[0].set_title('MinMax масштабирование')
ax[1].set_title('Z-оценка')
ax[2].set_title('Нормализация')
sns.distplot(sc1.fit_transform(data[["global_num"]].dropna()), ax=ax[0]);
sns.distplot(sc2.fit_transform(data[["global_num"]].dropna()), ax=ax[1]);
sns.distplot(sc3.fit_transform(data[["global_num"]].dropna()), ax=ax[2]);
fig.show()
fig, ax =plt.subplots(1,3, figsize=(20,5))
ax[0].set_title('MinMax масштабирование')
ax[1].set_title('Z-оценка')
ax[2].set title('Нормализация')
sns.distplot(sc1.fit_transform(data[["birth_year"]].dropna()), ax=ax[0]);
sns.distplot(sc2.fit_transform(data[["birth_year"]].dropna()), ax=ax[1]);
sns.distplot(sc3.fit_transform(data[["birth_year"]].dropna()), ax=ax[2]);
fig.show()
                                 \times 20,5))
 Saving...
                                    ние')
ax[1].set_title('Z-оценка')
ax[2].set_title('Нормализация')
sns.distplot(sc1.fit_transform(data[["contact_number"]].dropna()), ax=ax[0]);
sns.distplot(sc2.fit_transform(data[["contact_number"]].dropna()), ax=ax[1]);
sns.distplot(sc3.fit_transform(data[["contact_number"]].dropna()), ax=ax[2]);
fig.show()
```



/usr/local/lib/python3.6/dist-packages/seaborn/distributions.py:288: UserWarning: Dat warnings.warn(msg, UserWarning)

/usr/local/lib/python3.6/dist-packages/seaborn/distributions.py:288: UserWarning: Dat warnings.warn(msg, UserWarning)



Saving... ×