МОСКОВСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ
им. Н.Э. Баумана

Факультет «Информатика и система управления»
Кафедра ИУ-5 «Системы обработки информации и управления»

ОТЧЕТ

Лабораторная работа №5 по курсу
«Методы машинного обучения»

«Изучение линейных моделей, SVM и деревьев решений»

Исполнитель - студент группы ИУ5-21М:

Кауров Максим _____

Москва – 2020 год

Лабораторная работа №5

Цель работы: Изучить линейные модели, SVM и деревья решений.

Задание

Требуется выполнить следующие действия:

1. Выбрать набор данных (датасет) для решения задачи классификации или регресии.
2. В случае необходимости проведите удаление или заполнение пропусков и кодирование категориальных признаков.
3. С использованием метода `train_test_split` разделите выборку на обучающую и тестовую.
4. Обучите одну из линейных моделей, SVM и дерево решений. Оцените качество модели с помощью трех подходящих для задачи метрик. Сравните качество полученных моделей.
5. Произведите для каждой модели подбор одного гиперпараметра с использованием `GridSearchCV` и кросс-валидации.
6. Повторите пункт 4 для найденных оптимальных значения гиперпараметров. Сравните качество полученных моделей с качеством моделей, полученных в пункте 4.

Подключаем библиотеки:

In [0]:
```
from google.colab import files
from datetime import datetime
import graphviz
import matplotlib.pyplot as plt
import numpy as np
import pandas as pd
from sklearn.linear_model import Lasso, LinearRegression
from sklearn.metrics import mean_absolute_error
from sklearn.metrics import median_absolute_error, r2_score
from sklearn.model_selection import GridSearchCV
from sklearn.model_selection import ShuffleSplit
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.svm import NuSVR
from sklearn.tree import DecisionTreeRegressor
from sklearn.tree import export_graphviz, plot_tree

# Enable inline plots
%matplotlib inline

# Set plots formats to save high resolution PNG
from IPython.display import set_matplotlib_formats
set_matplotlib_formats("retina")
```

In [3]:
```
#Загрузим датасет
uploaded = files.upload()
```

Choose Files No file chosen

Upload widget is only available when the cell has been executed in the current browser session. Please rerun this cell to enable.

```
Saving datasets_418778_1048669_cbb20.csv to datasets_418778_1048669_cbb20.csv
```

Предварительная подготовка данных

Информация о датасете

В качестве датасета возьмем датасет с информацией о играх баскетбольных комманд колледжей.

Данные о содержании: (из источника, Kaggle)

RK (Only in cbb20): The ranking of the team at the end of the regular season according to barttorvik

TEAM: The Division I college basketball school

CONF: The Athletic Conference in which the school participates in (A10 = Atlantic 10, ACC = Atlantic Coast Conference, AE = America East, Amer = American, ASun = ASUN, B10 = Big Ten, B12 = Big 12, BE = Big East, BSky = Big Sky, BSth = Big South, BW = Big West, CAA = Colonial Athletic Association, CUSA = Conference USA, Horz = Horizon League, Ivy = Ivy League, MAAC = Metro Atlantic Athletic Conference, MAC = Mid-American Conference, MEAC = Mid-Eastern Athletic Conference, MVC = Missouri Valley Conference, MWC = Mountain West, NEC = Northeast Conference, OVC = Ohio Valley Conference, P12 = Pac-12, Pat = Patriot League, SB = Sun Belt, SC = Southern Conference, SEC = South Eastern Conference, Slnd = Southland Conference, Sum = Summit League, SWAC = Southwestern Athletic Conference, WAC = Western Athletic Conference, WCC = West Coast Conference)

G: Number of games played

W: Number of games won

ADJOE: Adjusted Offensive Efficiency (An estimate of the offensive efficiency (points scored per 100 possessions) a team would have against the average Division I defense)

ADJDE: Adjusted Defensive Efficiency (An estimate of the defensive efficiency (points allowed per 100 possessions) a team would have against the average Division I offense)

BARTHAG: Power Rating (Chance of beating an average Division I team)

EFG_O: Effective Field Goal Percentage Shot

EFG_D: Effective Field Goal Percentage Allowed

TOR: Turnover Percentage Allowed (Turnover Rate)

TORD: Turnover Percentage Committed (Steal Rate)

ORB: Offensive Rebound Percentage

DRB: Defensive Rebound Percentage

FTR : Free Throw Rate (How often the given team shoots Free Throws)

FTRD: Free Throw Rate Allowed

2P_O: Two-Point Shooting Percentage

2P_D: Two-Point Shooting Percentage Allowed

3P_O: Three-Point Shooting Percentage

3P_D: Three-Point Shooting Percentage Allowed

ADJ_T: Adjusted Tempo (An estimate of the tempo (possessions per 40 minutes) a team would have against the team that wants to play at an average Division I tempo)

WAB: Wins Above Bubble (The bubble refers to the cut off between making the NCAA March Madness Tournament and not making it)

POSTSEASON: Round where the given team was eliminated or where their season ended (R68 = First Four, R64 = Round of 64, R32 = Round of 32, S16 = Sweet Sixteen, E8 = Elite Eight, F4 = Final Four, 2ND = Runner-up, Champion = Winner of the NCAA March Madness Tournament for that given year)

SEED: Seed in the NCAA March Madness Tournament

YEAR: Season

In [0]:
```
data = pd.read_csv("datasets_418778_1048669_cbb20.csv")
```

Проверим типы данных в датасете:

In [6]:
```
data.dtypes
```

Out[6]:
```
RK           int64
TEAM        object
CONF        object
G            int64
W            int64
ADJOE      float64
ADJDE      float64
BARTHAG    float64
EFG_O      float64
EFG_D      float64
TOR        float64
TORD       float64
ORB        float64
DRB        float64
FTR        float64
FTRD       float64
2P_O       float64
2P_D       float64
3P_O       float64
3P_D       float64
ADJ_T      float64
WAB        float64
dtype: object
```

Посмотрим как это выглядит:

In [7]:
```
data.head()
```

Out[7]:

	RK	TEAM	CONF	G	W	ADJOE	ADJDE	BARTHAG	EFG_O	EFG_D	TOR	TORD	ORB	DRB	FTR	FTRD	2P_O	2P_D	3P_O	3P_D	ADJ_T	WAB
0	1	Kansas	B12	30	28	116.1	87.7	0.9616	53.7	43.7	18.7	18.6	32.6	26.4	35.8	23.2	54.9	42.4	34.1	30.5	67.4	10.8
1	2	Baylor	B12	30	26	114.5	88.4	0.9513	49.4	45.2	17.8	22.7	35.8	29.8	30.8	30.8	47.5	44.4	35.1	31.1	66.2	8.5
2	3	Gonzaga	WCC	33	31	121.3	94.3	0.9472	57.5	47.6	15.3	18.4	33.6	22.7	38.8	21.8	57.4	47.4	38.6	32.0	72.0	7.7
3	4	Dayton	A10	31	29	119.5	93.4	0.9445	59.7	46.6	18.0	18.8	26.4	26.6	33.9	30.9	62.3	45.1	37.1	33.0	67.5	6.8
4	5	Michigan St.	B10	31	22	114.8	91.3	0.9326	52.6	43.3	18.1	15.8	32.8	26.0	30.8	29.3	52.9	43.4	34.8	28.7	69.3	5.2

Нам не очень интересны столбцы TEAM и CONF, так что избавимся от них

In [0]:
```
data.drop(['TEAM', 'CONF'],axis='columns', inplace=True)
```

In [11]:
```
data.dtypes
```

Out[11]:
```
RK           int64
G            int64
W            int64
ADJOE      float64
ADJDE      float64
BARTHAG    float64
EFG_O      float64
EFG_D      float64
TOR        float64
TORD       float64
ORB        float64
DRB        float64
FTR        float64
FTRD       float64
2P_O       float64
2P_D       float64
3P_O       float64
3P_D       float64
ADJ_T      float64
WAB        float64
dtype: object
```

С оставшимися данными можем работать. Посмотримразмер датасета:

In [13]:
```
data.shape
```

Out[13]:
```
(353, 20)
```

Проверим основные статистические характеристики набора данных:

In [14]:
```
data.describe()
```

Out[14]:

	RK	G	W	ADJOE	ADJDE	BARTHAG	EFG_O	EFG_D	TOR	TORD	ORB	DRB	
count	353.000000	353.000000	353.000000	353.000000	353.000000	353.000000	353.000000	353.000000	353.000000	353.000000	353.000000	353.000000	353.(
mean	177.000000	30.186969	16.305949	102.241926	102.241926	0.497690	49.569555	49.606232	18.920397	18.897450	27.887819	27.967989	32.
std	102.046558	1.607564	5.484212	6.775256	6.430723	0.250529	2.793632	2.779841	2.020979	2.257429	3.996233	2.939827	4.
min	1.000000	24.000000	1.000000	80.100000	85.600000	0.019400	39.300000	41.200000	13.600000	14.000000	14.200000	19.000000	21.
25%	89.000000	29.000000	13.000000	97.300000	98.000000	0.281800	47.600000	47.600000	17.800000	17.400000	25.200000	26.000000	29.
50%	177.000000	30.000000	16.000000	102.200000	102.000000	0.480400	49.600000	49.500000	18.800000	18.700000	27.900000	28.000000	32.
75%	265.000000	31.000000	20.000000	106.700000	106.400000	0.720700	51.500000	51.500000	20.300000	20.300000	30.600000	29.900000	35.
max	353.000000	34.000000	31.000000	121.300000	122.700000	0.961600	59.700000	58.400000	26.600000	27.800000	40.100000	36.900000	48.

Проверим наличие пропусков в данных:

In [15]:
```
data.isnull().sum()
```

Out[15]:
```
RK         0
G          0
W          0
ADJOE      0
ADJDE      0
BARTHAG    0
EFG_O      0
EFG_D      0
TOR        0
TORD       0
ORB        0
DRB        0
FTR        0
FTRD       0
2P_O       0
2P_D       0
3P_O       0
3P_D       0
ADJ_T      0
WAB        0
dtype: int64
```

Разделение данных

Разделим данные на целевой столбец и признаки:

In [0]:
```
y = data["RK"]
X = data.drop("RK", axis=1)
```

In [17]:
```
print(X.head(), "\n")
print(y.head())
```

```
    G   W  ADJOE  ADJDE  BARTHAG  EFG_O  ...  2P_O  2P_D  3P_O  3P_D  ADJ_T   WAB
0  30  28  116.1   87.7   0.9616   53.7  ...  54.9  42.4  34.1  30.5   67.4  10.8
1  30  26  114.5   88.4   0.9513   49.4  ...  47.5  44.4  35.1  31.1   66.2   8.5
2  33  31  121.3   94.3   0.9472   57.5  ...  57.4  47.4  38.6  32.0   72.0   7.7
3  31  29  119.5   93.4   0.9445   59.7  ...  62.3  45.1  37.1  33.0   67.5   6.8
4  31  22  114.8   91.3   0.9326   52.6  ...  52.9  43.4  34.8  28.7   69.3   5.2

[5 rows x 19 columns]

0    1
1    2
2    3
3    4
4    5
Name: RK, dtype: int64
```

In [18]:
```
print(X.shape)
print(y.shape)
```

```
(353, 19)
(353,)
```

Предобработаем данные, чтобы методы работали лучше:

In [19]:
```
columns = X.columns
scaler = StandardScaler()
X = scaler.fit_transform(X)
pd.DataFrame(X, columns=columns).describe()
```

Out[19]:

	G	W	ADJOE	ADJDE	BARTHAG	EFG_O	EFG_D	TOR	TORD	ORB
count	3.530000e+02	3.530000e+02	3.530000e+02	3.530000e+02	3.530000e+02	3.530000e+02	3.530000e+02	3.530000e+02	3.530000e+02	3.530000e+02
mean	5.346683e-16	1.002660e-15	-1.090723e-15	3.073399e-15	-6.856335e-17	2.175786e-15	2.402862e-16	-5.095075e-16	-2.453184e-16	3.057045e-16
std	1.001419e+00	1.001419e+00	1.001419e+00	1.001419e+00	1.001419e+00	1.001419e+00	1.001419e+00	1.001419e+00	1.001419e+00	1.001419e+00
min	-3.854124e+00	-2.794873e+00	-3.272697e+00	-2.591551e+00	-1.911827e+00	-3.680919e+00	-3.028290e+00	-2.636321e+00	-2.172561e+00	-3.430042e+00
25%	-7.394130e-01	-6.036677e-01	-7.304435e-01	-6.605707e-01	-8.629571e-01	-7.056584e-01	-7.227319e-01	-5.551701e-01	-6.642848e-01	-6.735428e-01
50%	-1.164708e-01	-5.586642e-02	-6.196941e-03	-3.767379e-02	-6.910995e-02	1.127185e-02	-3.826948e-02	-5.965797e-02	-8.759108e-02	3.052523e-03
75%	5.064715e-01	6.745353e-01	6.589274e-01	6.475128e-01	8.914212e-01	6.923555e-01	6.822173e-01	6.836102e-01	6.221857e-01	6.796478e-01
max	2.375298e+00	2.683140e+00	2.816886e+00	3.185818e+00	1.854351e+00	3.631769e+00	3.167897e+00	3.805336e+00	3.949265e+00	3.060261e+00

Разделим выборку на тренировочную и тестовую:

In [0]:
```
X_train, X_test, y_train, y_test = train_test_split(X, y,
                                                    test_size=0.25, random_state=346705925)
```

In [21]:
```
print(X_train.shape)
print(X_test.shape)
print(y_train.shape)
print(y_test.shape)
```

```
(264, 19)
(89, 19)
(264,)
(89,)
```

Обучение моделей

Напишем функцию, которая считает метрики построенной модели:

In [0]:
```
def test_model(model):
    print("mean_absolute_error:",
          mean_absolute_error(y_test, model.predict(X_test)))
    print("median_absolute_error:",
          median_absolute_error(y_test, model.predict(X_test)))
    print("r2_score:",
          r2_score(y_test, model.predict(X_test)))
```

Линейная модель — Lasso

Запустим метод Lasso с гиперпараметром $\alpha = 1$:

In [23]:
```
las_1 = Lasso(alpha=1.0)
las_1.fit(X_train, y_train)
```

Out[23]:
```
Lasso(alpha=1.0, copy_X=True, fit_intercept=True, max_iter=1000,
      normalize=False, positive=False, precompute=False, random_state=None,
      selection='cyclic', tol=0.0001, warm_start=False)
```

Проверим метрики построенной модели:

In [24]:
```
test_model(las_1)
```

```
mean_absolute_error: 5.132358994321031
median_absolute_error: 4.602639306430007
r2_score: 0.9961588783795767
```

SVM

Запустим метод NuSVR с гиперпараметром $\nu = 0{,}5$:

In [25]:
```
nusvr_05 = NuSVR(nu=0.5, gamma='scale')
nusvr_05.fit(X_train, y_train)
```

Out[25]:
```
NuSVR(C=1.0, cache_size=200, coef0=0.0, degree=3, gamma='scale', kernel='rbf',
      max_iter=-1, nu=0.5, shrinking=True, tol=0.001, verbose=False)
```

Проверим метрики построенной модели:

In [26]:
```
test_model(nusvr_05)
```

```
mean_absolute_error: 79.04622918890769
median_absolute_error: 77.80523807923385
r2_score: 0.21886636832668083
```

SVM выдал гораздо более плохие результаты, чем Lasso.

Дерево решений

Попробуем дерево решений с неограниченной глубиной дерева:

In [27]:
```
dt_none = DecisionTreeRegressor(max_depth=None)
dt_none.fit(X_train, y_train)
```

Out[27]:
```
DecisionTreeRegressor(ccp_alpha=0.0, criterion='mse', max_depth=None,
                      max_features=None, max_leaf_nodes=None,
                      min_impurity_decrease=0.0, min_impurity_split=None,
                      min_samples_leaf=1, min_samples_split=2,
                      min_weight_fraction_leaf=0.0, presort='deprecated',
                      random_state=None, splitter='best')
```

Проверим метрики построенной модели:

In [28]:
```
test_model(dt_none)
```

```
mean_absolute_error: 2.5280898876404496
median_absolute_error: 2.0
r2_score: 0.9991512168865807
```

Древо решений показало результат в 2 раза лучше чем Lasso, и гораздо лучше чем SVM:

In [0]:
```
def stat_tree(estimator):
    n_nodes = estimator.tree_.node_count
    children_left = estimator.tree_.children_left
    children_right = estimator.tree_.children_right

    node_depth = np.zeros(shape=n_nodes, dtype=np.int64)
    is_leaves = np.zeros(shape=n_nodes, dtype=bool)
    stack = [(0, -1)]  # seed is the root node id and its parent depth
    while len(stack) > 0:
        node_id, parent_depth = stack.pop()
        node_depth[node_id] = parent_depth + 1

        # If we have a test node
        if (children_left[node_id] != children_right[node_id]):
            stack.append((children_left[node_id], parent_depth + 1))
            stack.append((children_right[node_id], parent_depth + 1))
        else:
            is_leaves[node_id] = True

    print("Всего узлов:", n_nodes)
    print("Листовых узлов:", sum(is_leaves))
    print("Глубина дерева:", max(node_depth))
    print("Минимальная глубина листьев дерева:", min(node_depth[is_leaves]))
    print("Средняя глубина листьев дерева:", node_depth[is_leaves].mean())
```

In [30]:
```
stat_tree(dt_none)
```

```
Всего узлов: 527
Листовых узлов: 264
Глубина дерева: 9
Минимальная глубина листьев дерева: 7
Средняя глубина листьев дерева: 8.159090909090908
```

Подбор гиперпараметра K

Линейная модель — Lasso

Введем список настраиваемых параметров:

In [31]:
```
param_range = np.arange(0.001, 2.01, 0.1)
tuned_parameters = [{'alpha': param_range}]
tuned_parameters
```

Out[31]:
```
[{'alpha': array([1.000e-03, 1.010e-01, 2.010e-01, 3.010e-01, 4.010e-01, 5.010e-01,
         6.010e-01, 7.010e-01, 8.010e-01, 9.010e-01, 1.001e+00, 1.101e+00,
         1.201e+00, 1.301e+00, 1.401e+00, 1.501e+00, 1.601e+00, 1.701e+00,
         1.801e+00, 1.901e+00, 2.001e+00])}]
```

Запустим подбор параметра:

In [32]:
```
gs = GridSearchCV(Lasso(), tuned_parameters,
                  cv=ShuffleSplit(n_splits=10), scoring="r2",
                  return_train_score=True, n_jobs=-1)
gs.fit(X, y)
gs.best_estimator_
```

Out[32]:
```
Lasso(alpha=0.001, copy_X=True, fit_intercept=True, max_iter=1000,
      normalize=False, positive=False, precompute=False, random_state=None,
      selection='cyclic', tol=0.0001, warm_start=False)
```

Проверим результаты при разных значения гиперпараметра на тренировочном наборе данных:

In [33]:
```
plt.plot(param_range, gs.cv_results_["mean_train_score"]);
```

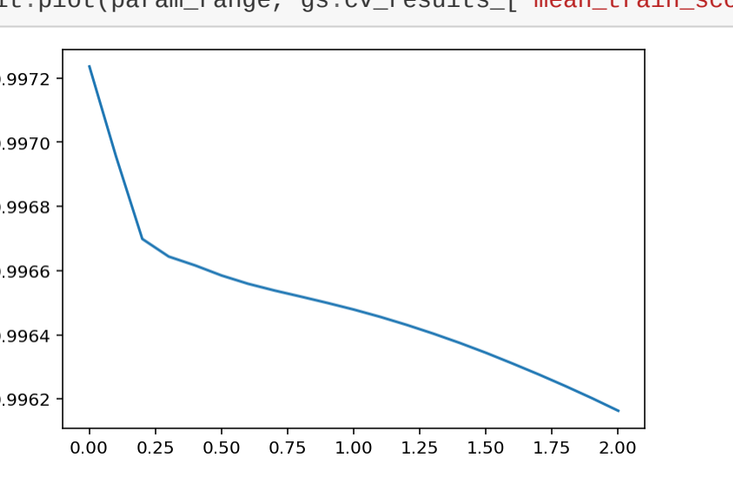

Видно, что метод Lasso здесь не особо хорошо справляется, и выдает странный график.

На тестовом наборе данных картина ровно та же:

In [34]:
```
plt.plot(param_range, gs.cv_results_["mean_test_score"]);
```

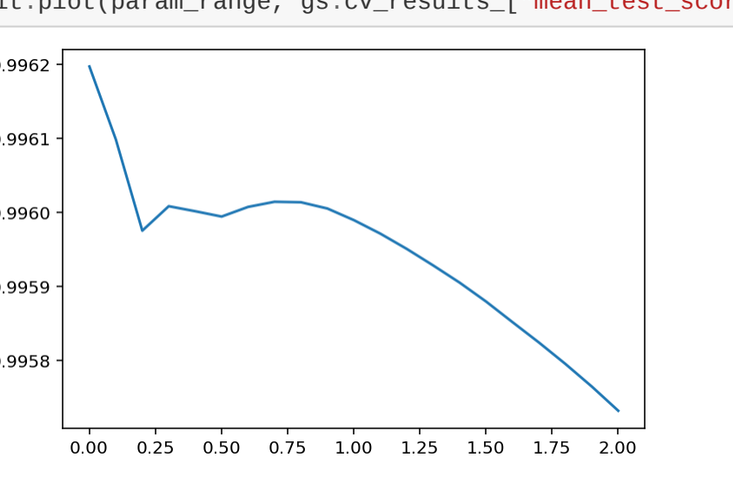

Будем считать, что GridSearch показал, что нам нужна обычная линейная регрессия:

In [35]:
```
reg = LinearRegression()
reg.fit(X_train, y_train)
test_model(reg)
```

```
mean_absolute_error: 4.761368518630553
median_absolute_error: 4.383129395277479
r2_score: 0.996808999860798
```

Получили немного лучший результат, однако очевидно,что данный метод не может дать хороший результат для данной выборки.

SVM

Введем список настраиваемых параметров:

In [36]:
```
param_range = np.arange(0.1, 1.01, 0.1)
tuned_parameters = [{'nu': param_range}]
tuned_parameters
```

Out[36]:
```
[{'nu': array([0.1, 0.2, 0.3, 0.4, 0.5, 0.6, 0.7, 0.8, 0.9, 1. ])}]
```

Запустим подбор параметра:

In [37]:
```
gs = GridSearchCV(NuSVR(gamma='scale'), tuned_parameters,
                  cv=ShuffleSplit(n_splits=10), scoring="r2",
                  return_train_score=True, n_jobs=-1)
gs.fit(X, y)
gs.best_estimator_
```

Out[37]:
```
NuSVR(C=1.0, cache_size=200, coef0=0.0, degree=3, gamma='scale', kernel='rbf',
      max_iter=-1, nu=0.9, shrinking=True, tol=0.001, verbose=False)
```

Проверим результаты при разных значения гиперпараметра на тренировочном наборе данных:

In [38]:
```
plt.plot(param_range, gs.cv_results_["mean_train_score"]);
```

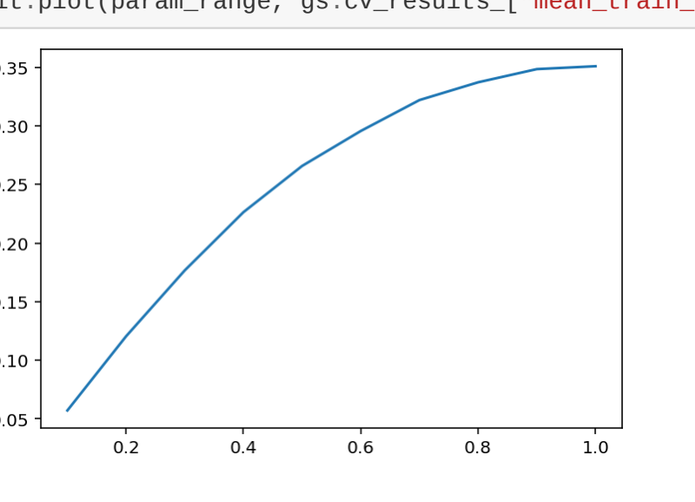

Видно, что метод NuSVR справляется лучше, но не глобально.

На тестовом наборе данных картина ровно та же:

In [39]:
```
plt.plot(param_range, gs.cv_results_["mean_test_score"]);
```

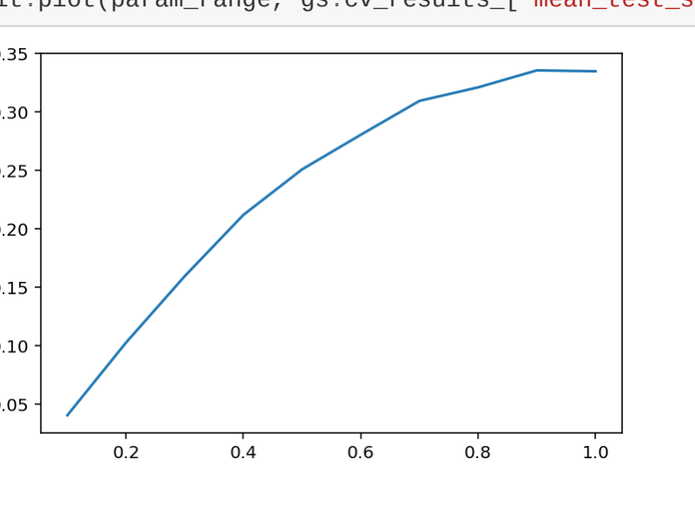

Проведем обучение заново с параметром 0,3

In [53]:
```
nusvr_05 = NuSVR(nu=0.3, gamma='scale')
nusvr_05.fit(X_train, y_train)
```

Out[53]:
```
NuSVR(C=1.0, cache_size=200, coef0=0.0, degree=3, gamma='scale', kernel='rbf',
      max_iter=-1, nu=0.3, shrinking=True, tol=0.001, verbose=False)
```

In [55]:
```
test_model(nusvr_05)
```

```
mean_absolute_error: 82.97476834511633
median_absolute_error: 87.70985240826414
r2_score: 0.1449776491586927
```

К сожалению, результаты снова ухудшились

Дерево решений

Введем список настраиваемых параметров:

In [40]:
```
param_range = np.arange(1, 51, 2)
tuned_parameters = [{'max_depth': param_range}]
tuned_parameters
```

Out[40]:
```
[{'max_depth': array([ 1,  3,  5,  7,  9, 11, 13, 15, 17, 19, 21, 23, 25, 27, 29, 31, 33,
         35, 37, 39, 41, 43, 45, 47, 49])}]
```

Запустим подбор параметра:

In [41]:
```
gs = GridSearchCV(DecisionTreeRegressor(), tuned_parameters,
                  cv=ShuffleSplit(n_splits=10), scoring="r2",
                  return_train_score=True, n_jobs=-1)
gs.fit(X, y)
gs.best_estimator_
```

Out[41]:
```
DecisionTreeRegressor(ccp_alpha=0.0, criterion='mse', max_depth=39,
                      max_features=None, max_leaf_nodes=None,
                      min_impurity_decrease=0.0, min_impurity_split=None,
                      min_samples_leaf=1, min_samples_split=2,
                      min_weight_fraction_leaf=0.0, presort='deprecated',
                      random_state=None, splitter='best')
```

Проверим результаты при разных значения гиперпараметра на тренировочном наборе данных:

In [42]:
```
plt.plot(param_range, gs.cv_results_["mean_train_score"]);
```

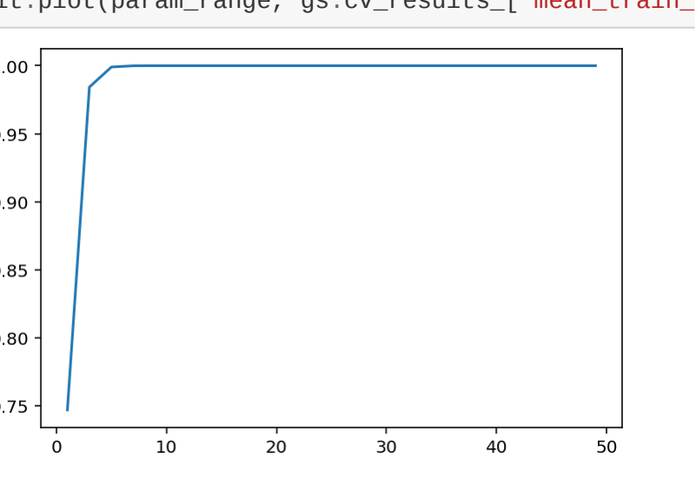

Видно, что на тестовой выборке модель легко переобучается.

На тестовом наборе данных картина аналогична:

In [43]:
```
plt.plot(param_range, gs.cv_results_["mean_test_score"]);
```

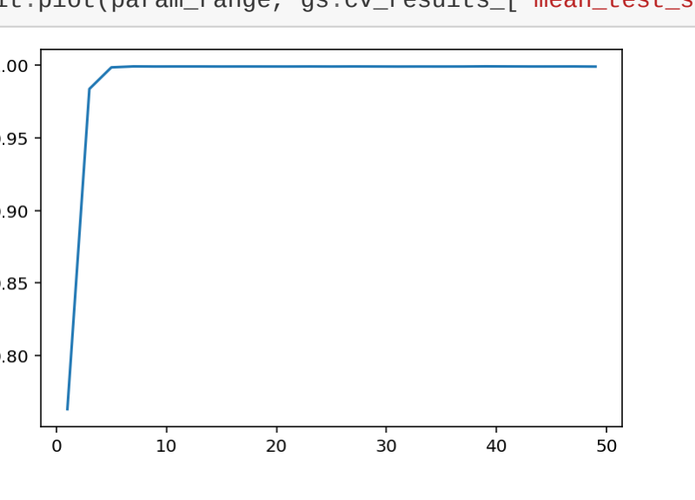

Проведем дополнительное исследование в районе пика.

In [44]:
```
param_range = np.arange(7, 14, 1)
tuned_parameters = [{'max_depth': param_range}]
tuned_parameters
```

Out[44]:
```
[{'max_depth': array([ 7,  8,  9, 10, 11, 12, 13])}]
```

In [45]:
```
gs = GridSearchCV(DecisionTreeRegressor(), tuned_parameters,
                  cv=ShuffleSplit(n_splits=10), scoring="r2",
                  return_train_score=True, n_jobs=-1)
gs.fit(X, y)
gs.best_estimator_
```

Out[45]:
```
DecisionTreeRegressor(ccp_alpha=0.0, criterion='mse', max_depth=11,
                      max_features=None, max_leaf_nodes=None,
                      min_impurity_decrease=0.0, min_impurity_split=None,
                      min_samples_leaf=1, min_samples_split=2,
                      min_weight_fraction_leaf=0.0, presort='deprecated',
                      random_state=None, splitter='best')
```

In [46]:
```
plt.plot(param_range, gs.cv_results_["mean_test_score"]);
```

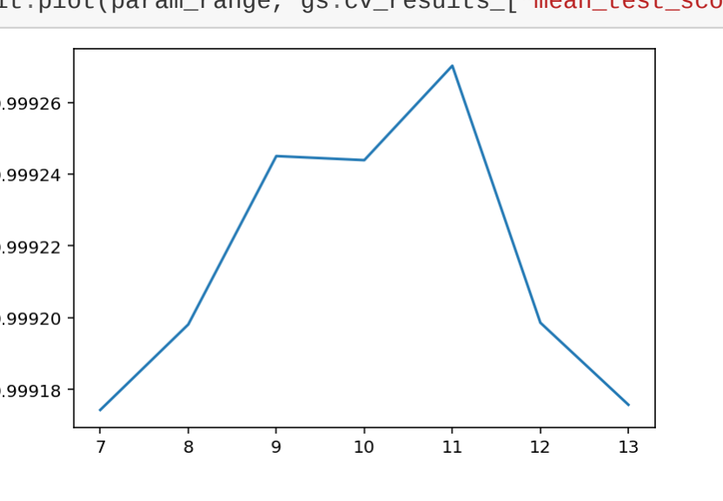

Получили, что глубину дерева необходимо ограничить 11 уровнями. Проверим этот результат.

In [57]:
```
reg = gs.best_estimator_
reg.fit(X_train, y_train)
test_model(reg)
```

```
mean_absolute_error: 2.7865168539325844
median_absolute_error: 2.0
r2_score: 0.9989853135037561
```

Вновь посмотрим статистику получившегося дерева решений.

In [48]:
```
stat_tree(reg)
```

```
Всего узлов: 527
Листовых узлов: 264
Глубина дерева: 9
Минимальная глубина листьев дерева: 7
Средняя глубина листьев дерева: 8.159090909090908
```

В целом получили примерно тот же результат. Посмотрим на построенное дерево.

In [49]:
```
plot_tree(reg, filled=True);
```

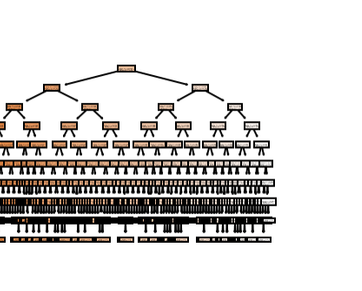

Вывод функции `plot_tree` выглядит весьма странно. Видимо, для настолько больших деревьев решений она не предназначена.

In [50]:
```
dot_data = export_graphviz(reg, out_file=None, feature_names=columns,
                           filled=True, rounded=True,
                           special_characters=True)
graph = graphviz.Source(dot_data)
graph
```

Out[50]:

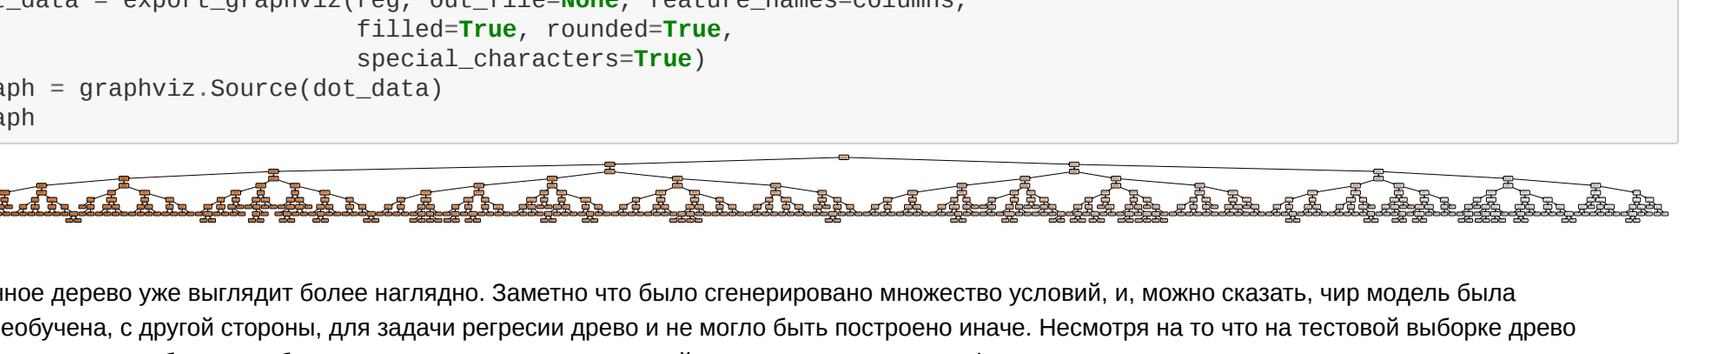

Данное дерево уже выглядит более наглядно. Заметно что было сгенерировано множество условий, и, можно сказать, чир модель была переобучена, с другой стороны, для задачи регресии древо и не могло быть построено иначе. Несмотря на то что на тестовой выборке древо показало свою работоспособность, лучше использовать данный метод для задач классификации.