МОСКОВСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ
им. Н.Э. Баумана

Факультет «Информатика и система управления»
Кафедра ИУ-5 «Системы обработки информации и управления»

ОТЧЕТ

Лабораторная работа №6 по курсу «Методы машинного обучения»

«Изучение ансамблей моделей машинного обучения.»

Исполнитель - студент группы ИУ5-21М:

Кауров Максим _________

Москва – 2020 год

Цель лабораторной работы

Изучить ансамбли моделей машинного обучения.

Задание

Требуется выполнить следующие действия:

1. Выбрать набор данных (датасет) для решения задачи классификации или регресии.
2. В случае необходимости проведите удаление или заполнение пропусков и кодирование категориальных признаков.
3. С использованием метода `train_test_split` разделите выборку на обучающую и тестовую.
4. Обучите две ансамблевые модели. Оцените качество модели с помощью одной из подходящих для задачи метрик. Сравните качество полученных моделей.
5. Произведите для каждой модели подбор одного гиперпараметра. В зависимости от используемой библиотеки можно применять функцию `GridSearchCV`, использовать перебор параметров в цикле, или использовать другие методы.
6. Повторите пункт 4 для найденных оптимальных значения гиперпараметров. Сравните качество полученных моделей с качеством моделей, полученных в пункте 4.

Ход выполнения работы

Подключим все необходимые библиотеки и настроим отображение графиков:

In [0]:
```python
from google.colab import files
from datetime import datetime
import matplotlib.pyplot as plt
import numpy as np
import pandas as pd
from sklearn.ensemble import GradientBoostingRegressor
from sklearn.ensemble import RandomForestRegressor
from sklearn.metrics import mean_absolute_error
from sklearn.metrics import median_absolute_error, r2_score
from sklearn.model_selection import GridSearchCV
from sklearn.model_selection import ShuffleSplit
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler

# Enable inline plots
%matplotlib inline

# Set plots formats to save high resolution PNG
from IPython.display import set_matplotlib_formats
set_matplotlib_formats("retina")
```

Предварительная подготовка данных

В качестве датасета возьмем датасет с информацией о играх баскетбольных комманд колледжей.

Данные о содержании: (из источника, Kaggle)

RK (Only in cbb20): The ranking of the team at the end of the regular season according to barttorvik

TEAM: The Division I college basketball school

CONF: The Athletic Conference in which the school participates in (A10 = Atlantic 10, ACC = Atlantic Coast Conference, AE = America East, Amer = American, ASun = ASUN, B10 = Big Ten, B12 = Big 12, BE = Big East, BSky = Big Sky, BSth = Big South, BW = Big West, CAA = Colonial Athletic Association, CUSA = Conference USA, Horz = Horizon League, Ivy = Ivy League, MAAC = Metro Atlantic Athletic Conference, MAC = Mid-American Conference, MEAC = Mid-Eastern Athletic Conference, MVC = Missouri Valley Conference, MWC = Mountain West, NEC = Northeast Conference, OVC = Ohio Valley Conference, P12 = Pac-12, Pat = Patriot League, SB = Sun Belt, SC = Southern Conference, SEC = South Eastern Conference, Slnd = Southland Conference, Sum = Summit League, SWAC = Southwestern Athletic Conference, WAC = Western Athletic Conference, WCC = West Coast Conference)

G: Number of games played

W: Number of games won

ADJOE: Adjusted Offensive Efficiency (An estimate of the offensive efficiency (points scored per 100 possessions) a team would have against the average Division I defense)

ADJDE: Adjusted Defensive Efficiency (An estimate of the defensive efficiency (points allowed per 100 possessions) a team would have against the average Division I offense)

BARTHAG: Power Rating (Chance of beating an average Division I team)

EFG_O: Effective Field Goal Percentage Shot

EFG_D: Effective Field Goal Percentage Allowed

TOR: Turnover Percentage Allowed (Turnover Rate)

TORD: Turnover Percentage Committed (Steal Rate)

ORB: Offensive Rebound Percentage

DRB: Defensive Rebound Percentage

FTR : Free Throw Rate (How often the given team shoots Free Throws)

FTRD: Free Throw Rate Allowed

2P_O: Two-Point Shooting Percentage

2P_D: Two-Point Shooting Percentage Allowed

3P_O: Three-Point Shooting Percentage

3P_D: Three-Point Shooting Percentage Allowed

ADJ_T: Adjusted Tempo (An estimate of the tempo (possessions per 40 minutes) a team would have against the team that wants to play at an average Division I tempo)

WAB: Wins Above Bubble (The bubble refers to the cut off between making the NCAA March Madness Tournament and not making it)

POSTSEASON: Round where the given team was eliminated or where their season ended (R68 = First Four, R64 = Round of 64, R32 = Round of 32, S16 = Sweet Sixteen, E8 = Elite Eight, F4 = Final Four, 2ND = Runner-up, Champion = Winner of the NCAA March Madness Tournament for that given year)

SEED: Seed in the NCAA March Madness Tournament

YEAR: Season

Поставим задачу предсказания количества оценок фильма по данным характеристикам. Построим модель машинного обучения для данного набора и решим задачу регрессии.

In [2]:
```python
uploaded = files.upload()
```

Choose Files No file chosen

Upload widget is only available when the cell has been executed in the current browser session. Please rerun this cell to enable.

```
Saving datasets_418778_1048669_cbb20.csv to datasets_418778_1048669_cbb20.csv
```

In [0]:
```python
data = pd.read_csv("datasets_418778_1048669_cbb20.csv")
```

Проверим полученные типы:

In [0]:
```python
#Уберем нечисловые столбцы с данными
data.drop(['TEAM', 'CONF'],axis='columns', inplace=True)
```

In [6]:
```python
data.dtypes
```

Out[6]:
```
RK            int64
G             int64
W             int64
ADJOE       float64
ADJDE       float64
BARTHAG     float64
EFG_O       float64
EFG_D       float64
TOR         float64
TORD        float64
ORB         float64
DRB         float64
FTR         float64
FTRD        float64
2P_O        float64
2P_D        float64
3P_O        float64
3P_D        float64
ADJ_T       float64
WAB         float64
dtype: object
```

Посмотрим на данные в данном наборе данных:

In [7]:
```python
data.head()
```

Out[7]:

	RK	G	W	ADJOE	ADJDE	BARTHAG	EFG_O	EFG_D	TOR	TORD	ORB	DRB	FTR	FTRD	2P_O	2P_D	3P_O	3P_D	ADJ_T	WAB
0	1	30	28	116.1	87.7	0.9616	53.7	43.7	18.7	18.6	32.6	26.4	35.8	23.2	54.9	42.4	34.1	30.5	67.4	10.8
1	2	30	26	114.5	88.4	0.9513	49.4	45.2	17.8	22.7	35.8	29.8	30.8	30.8	47.5	44.4	35.1	31.1	66.2	8.5
2	3	33	31	121.3	94.3	0.9472	57.5	47.6	15.3	18.4	33.6	22.7	38.8	21.8	57.4	47.4	38.6	32.0	72.0	7.7
3	4	31	29	119.5	93.4	0.9445	59.7	46.6	18.0	18.8	26.4	26.6	33.9	30.9	62.3	45.1	37.1	33.0	67.5	6.8
4	5	31	22	114.8	91.3	0.9326	52.6	43.3	18.1	15.8	32.8	26.0	30.8	29.3	52.9	43.4	34.8	28.7	69.3	5.2

Проверим размер набора данных:

In [9]:
```python
data.shape
```

Out[9]:
```
(353, 20)
```

Проверим основные статистические характеристики набора данных:

In [10]:
```python
data.describe()
```

Out[10]:

	RK	G	W	ADJOE	ADJDE	BARTHAG	EFG_O	EFG_D	TOR	TORD	ORB	DRB
count	353.000000	353.000000	353.000000	353.000000	353.000000	353.000000	353.000000	353.000000	353.000000	353.000000	353.000000	353.000000
mean	177.000000	30.186969	16.305949	102.241926	102.241926	0.497690	49.568555	49.606232	18.920397	18.897450	27.887819	27.967989
std	102.046558	1.607564	5.484212	6.775256	6.430723	0.250529	2.793632	2.779841	2.020979	2.257429	3.996233	2.939827
min	1.000000	24.000000	1.000000	80.100000	85.600000	0.019400	39.300000	41.200000	13.600000	14.000000	14.200000	19.000000
25%	89.000000	29.000000	13.000000	97.300000	98.000000	0.281800	47.600000	47.600000	17.800000	17.400000	25.200000	26.000000
50%	177.000000	30.000000	16.000000	102.200000	102.000000	0.480400	49.600000	49.500000	18.800000	18.700000	27.900000	28.000000
75%	265.000000	31.000000	20.000000	106.700000	106.400000	0.720700	51.500000	51.500000	20.300000	20.300000	30.600000	29.900000
max	353.000000	34.000000	31.000000	121.300000	122.700000	0.961600	59.700000	58.400000	26.600000	27.800000	40.100000	36.900000

Проверим наличие пропусков в данных:

In [11]:
```python
data.isnull().sum()
```

Out[11]:
```
RK         0
G          0
W          0
ADJOE      0
ADJDE      0
BARTHAG    0
EFG_O      0
EFG_D      0
TOR        0
TORD       0
ORB        0
DRB        0
FTR        0
FTRD       0
2P_O       0
2P_D       0
3P_O       0
3P_D       0
ADJ_T      0
WAB        0
dtype: int64
```

Разделение данных

Разделим данные на целевой столбец и признаки:

In [0]:
```python
y = data["RK"]
X = data.drop("RK", axis=1)
```

In [13]:
```python
print(X.head(), "\n")
print(y.head())
```

```
    G   W  ADJOE  ADJDE  BARTHAG  EFG_O  ...  2P_O  2P_D  3P_O  3P_D  ADJ_T   WAB
0  30  28  116.1   87.7   0.9616   53.7  ...  54.9  42.4  34.1  30.5   67.4  10.8
1  30  26  114.5   88.4   0.9513   49.4  ...  47.5  44.4  35.1  31.1   66.2   8.5
2  33  31  121.3   94.3   0.9472   57.5  ...  57.4  47.4  38.6  32.0   72.0   7.7
3  31  29  119.5   93.4   0.9445   59.7  ...  62.3  45.1  37.1  33.0   67.5   6.8
4  31  22  114.8   91.3   0.9326   52.6  ...  52.9  43.4  34.8  28.7   69.3   5.2

[5 rows x 19 columns]

0    1
1    2
2    3
3    4
4    5
Name: RK, dtype: int64
```

In [14]:
```python
print(X.shape)
print(y.shape)
```

```
(353, 19)
(353,)
```

Предобработаем данные, чтобы методы работали лучше:

In [15]:
```python
columns = X.columns
scaler = StandardScaler()
X = scaler.fit_transform(X)
pd.DataFrame(X, columns=columns).describe()
```

Out[15]:

	G	W	ADJOE	ADJDE	BARTHAG	EFG_O	EFG_D	TOR	TORD	ORB
count	3.530000e+02	3.530000e+02	3.530000e+02	3.530000e+02	3.530000e+02	3.530000e+02	3.530000e+02	3.530000e+02	3.530000e+02	3.530000e+02
mean	5.346683e-16	1.002660e-15	-1.090723e-15	3.073399e-15	-6.856335e-17	2.175786e-15	2.402862e-16	-5.095075e-16	-2.453184e-16	3.057045e-16
std	1.001419e+00	1.001419e+00	1.001419e+00	1.001419e+00	1.001419e+00	1.001419e+00	1.001419e+00	1.001419e+00	1.001419e+00	1.001419e+00
min	-3.854124e+00	-2.794873e+00	-3.272697e+00	-2.591551e+00	-1.911827e+00	-3.680919e+00	-3.028290e+00	-2.636321e+00	-2.172561e+00	-3.430042e+00
25%	-7.394130e-01	-6.036677e-01	-7.304435e-01	-6.605707e-01	-8.629571e-01	-7.056584e-01	-7.227319e-01	-5.551701e-01	-6.642848e-01	-6.735428e-01
50%	-1.164708e-01	-5.586642e-02	-6.196941e-03	-3.767379e-02	-6.910995e-02	1.127185e-02	-3.826948e-02	-5.965797e-02	-8.759108e-02	3.052523e-03
75%	5.064715e-01	6.745353e-01	6.589274e-01	6.475128e-01	8.914212e-01	6.923555e-01	6.822173e-01	6.836102e-01	6.221857e-01	6.796478e-01
max	2.375298e+00	2.683140e+00	2.816886e+00	3.185818e+00	1.854351e+00	3.631769e+00	3.167897e+00	3.805336e+00	3.949265e+00	3.060261e+00

Разделим выборку на тренировочную и тестовую:

In [0]:
```python
X_train, X_test, y_train, y_test = train_test_split(X, y,
                                                    test_size=0.25, random_state=346705925)
```

In [17]:
```python
print(X_train.shape)
print(X_test.shape)
print(y_train.shape)
print(y_test.shape)
```

```
(264, 19)
(89, 19)
(264,)
(89,)
```

Обучение моделей

Напишем функцию, которая считает метрики построенной модели:

In [0]:
```python
def test_model(model):
    print("mean_absolute_error:",
          mean_absolute_error(y_test, model.predict(X_test)))
    print("median_absolute_error:",
          median_absolute_error(y_test, model.predict(X_test)))
    print("r2_score:",
          r2_score(y_test, model.predict(X_test)))
```

Случайный лес

Попробуем случайный лес с гиперпараметром $n = 264$:

In [23]:
```python
ran_264 = RandomForestRegressor(n_estimators=264)
ran_264.fit(X_train, y_train)
```

Out[23]:
```
RandomForestRegressor(bootstrap=True, ccp_alpha=0.0, criterion='mse',
                      max_depth=None, max_features='auto', max_leaf_nodes=None,
                      max_samples=None, min_impurity_decrease=0.0,
                      min_impurity_split=None, min_samples_leaf=1,
                      min_samples_split=2, min_weight_fraction_leaf=0.0,
                      n_estimators=264, n_jobs=None, oob_score=False,
                      random_state=None, verbose=0, warm_start=False)
```

Проверим метрики построенной модели:

In [24]:
```python
test_model(ran_264)
```

```
mean_absolute_error: 1.4386278515491995
median_absolute_error: 0.9886363636363669
r2_score: 0.9996324988701671
```

Видно, что данный метод даже без настройки гиперпараметров уже показывает очень неплохой результат.

Градиентный бустинг

Попробуем градиентный бустинг с гиперпараметром $n = 264$:

In [30]:
```python
gr_264 = GradientBoostingRegressor(n_estimators=264)
gr_264.fit(X_train, y_train)
```

Out[30]:
```
GradientBoostingRegressor(alpha=0.9, ccp_alpha=0.0, criterion='friedman_mse',
                          init=None, learning_rate=0.1, loss='ls', max_depth=3,
                          max_features=None, max_leaf_nodes=None,
                          min_impurity_decrease=0.0, min_impurity_split=None,
                          min_samples_leaf=1, min_samples_split=2,
                          min_weight_fraction_leaf=0.0, n_estimators=264,
                          n_iter_no_change=None, presort='deprecated',
                          random_state=None, subsample=1.0, tol=0.0001,
                          validation_fraction=0.1, verbose=0, warm_start=False)
```

Проверим метрики построенной модели:

In [31]:
```python
test_model(gr_264)
```

```
mean_absolute_error: 1.2759182951497932
median_absolute_error: 1.0829624494705854
r2_score: 0.999768988217112
```

Ожидаемо градиентный бустинг оказался немного лучше по сравнению со случайным лесом.

Подбор гиперпараметра n

Случайный лес

Введем список настраиваемых параметров:

In [35]:
```python
param_range = np.arange(10, 201, 10)
tuned_parameters = [{'n_estimators': param_range}]
tuned_parameters
```

Out[35]:
```
[{'n_estimators': array([ 10,  20,  30,  40,  50,  60,  70,  80,  90, 100, 110, 120, 130,
         140, 150, 160, 170, 180, 190, 200])}]
```

Запустим подбор параметра:

In [36]:
```python
gs = GridSearchCV(RandomForestRegressor(), tuned_parameters,
                  cv=ShuffleSplit(n_splits=10), scoring="r2",
                  return_train_score=True, n_jobs=-1)
gs.fit(X, y)
gs.best_estimator_
```

Out[36]:
```
RandomForestRegressor(bootstrap=True, ccp_alpha=0.0, criterion='mse',
                      max_depth=None, max_features='auto', max_leaf_nodes=None,
                      max_samples=None, min_impurity_decrease=0.0,
                      min_impurity_split=None, min_samples_leaf=1,
                      min_samples_split=2, min_weight_fraction_leaf=0.0,
                      n_estimators=160, n_jobs=None, oob_score=False,
                      random_state=None, verbose=0, warm_start=False)
```

Проверим результаты при разных значения гиперпараметра на тренировочном наборе данных:

In [37]:
```python
plt.plot(param_range, gs.cv_results_["mean_train_score"]);
```

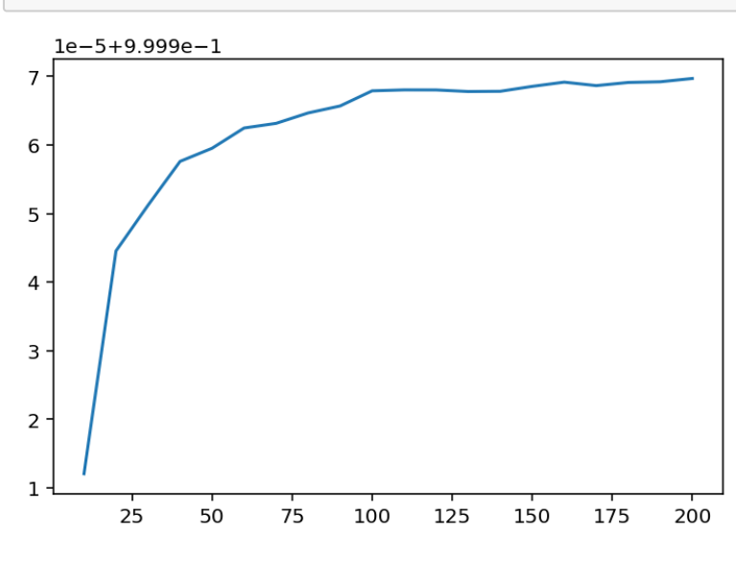

В целом результат ожидаемый — чем больше обученных моделей, тем лучше.

На тестовом наборе данных картина похожа:

In [38]:
```python
plt.plot(param_range, gs.cv_results_["mean_test_score"]);
```

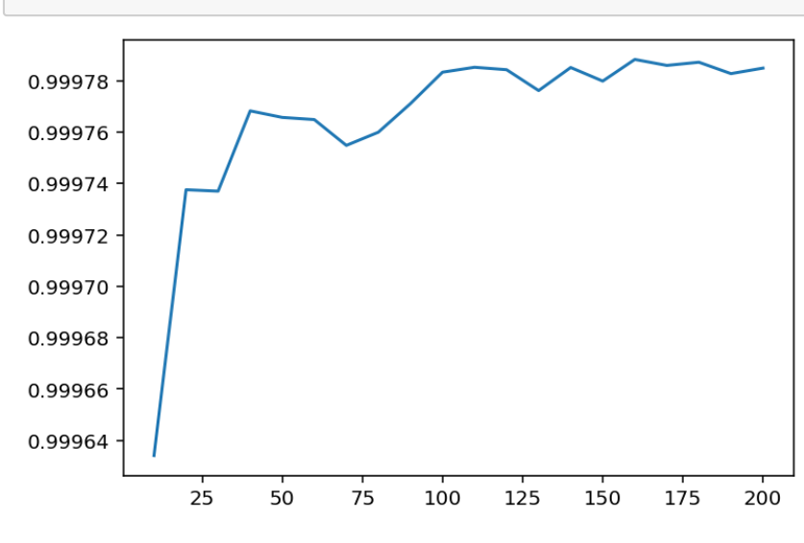

Из-за присутствия элемента случайности, график немного скачет. Однако это не мешает найти лучший результат.

In [39]:
```python
reg = gs.best_estimator_
reg.fit(X_train, y_train)
test_model(reg)
```

```
mean_absolute_error: 1.4076544943820246
median_absolute_error: 1.0437499999999886
r2_score: 0.999668509863967
```

Данная модель оказалась примерно такая же как и исходная.

Градиентный бустинг

Список настраиваемых параметров оставим тем же.

In [40]:
```python
tuned_parameters
```

Out[40]:
```
[{'n_estimators': array([ 10,  20,  30,  40,  50,  60,  70,  80,  90, 100, 110, 120, 130,
         140, 150, 160, 170, 180, 190, 200])}]
```

Запустим подбор параметра:

In [41]:
```python
gs = GridSearchCV(GradientBoostingRegressor(), tuned_parameters,
                  cv=ShuffleSplit(n_splits=10), scoring="r2",
                  return_train_score=True, n_jobs=-1)
gs.fit(X, y)
gs.best_estimator_
```

Out[41]:
```
GradientBoostingRegressor(alpha=0.9, ccp_alpha=0.0, criterion='friedman_mse',
                          init=None, learning_rate=0.1, loss='ls', max_depth=3,
                          max_features=None, max_leaf_nodes=None,
                          min_impurity_decrease=0.0, min_impurity_split=None,
                          min_samples_leaf=1, min_samples_split=2,
                          min_weight_fraction_leaf=0.0, n_estimators=70,
                          n_iter_no_change=None, presort='deprecated',
                          random_state=None, subsample=1.0, tol=0.0001,
                          validation_fraction=0.1, verbose=0, warm_start=False)
```

Проверим результаты при разных значения гиперпараметра на тренировочном наборе данных:

In [42]:
```python
plt.plot(param_range, gs.cv_results_["mean_train_score"]);
```

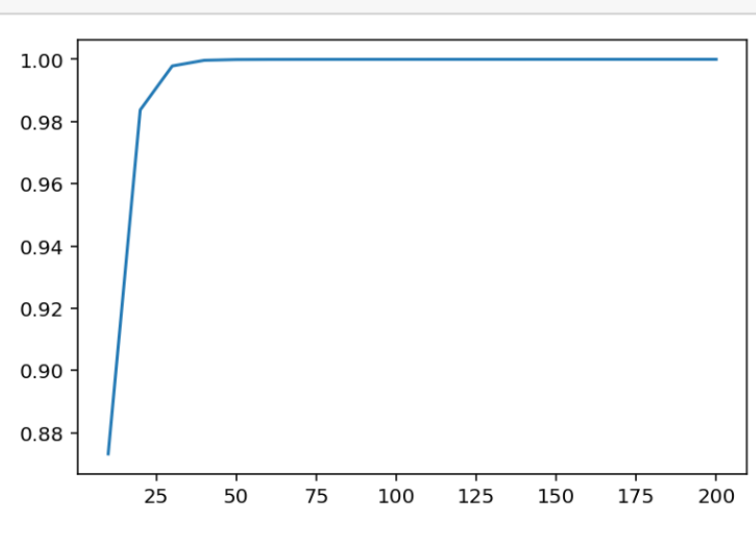

Картина та же: чем больше подмоделей, тем лучше. Однако после определенного момента результат достигает пика и больше не меняется

На тестовом наборе данных картина ровно та же:

In [43]:
```python
plt.plot(param_range, gs.cv_results_["mean_test_score"]);
```

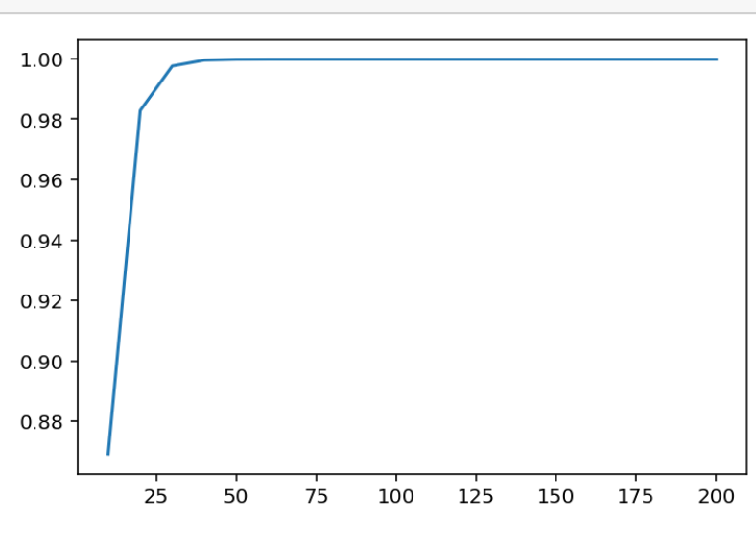

Однако из полученных результатов можно выделить явную тенденцию: чем больше моделей тем лучше.

In [44]:
```python
reg = gs.best_estimator_
reg.fit(X_train, y_train)
test_model(reg)
```

```
mean_absolute_error: 1.289725144853649
median_absolute_error: 1.1427072825601954
r2_score: 0.9997635451970246
```